# 先验与约束驱动的蛋白质定向进化智能体：GB1 四位点景观上的七臂对照研究


**Abstract**

机器学习指导的定向进化通常把"下一轮测哪些变体"交给一个在少量标签上训练的预测器，或者交给一个语言模型去挑选。本文在 GB1 四位点适应度景观（149,361 条实测变体，公开深度突变扫描作为虚拟评估器）上问一个更具体的问题：**在第一轮之前就已经存在的信息，能不能替代"让模型多挑几轮"**。我们把结构坐标、物理化学性质与 62 条可引用的文献证据编译成一个显式的、可消融的先验，把每一步的非序列约束写成带证据来源的规则集，并在同起点、同预算（192 条起始标签 + 3 轮 × 96 条）下对照七种策略，每种 15 个随机种子。结果有三点。其一，不使用任何多突变标签的证据先验，在三突变以上子集上的排序能力达到 $\rho = +0.295$，与使用实测单突变标签的上界（$\rho = +0.294$）持平，其前 96 名中的最好变体为 6.124。其二，证据先验加约束把命中全局最优（FWAA，fitness 8.762）的种子比例从预测器贪心的 20% 提升到 60%（配对 McNemar 检验 $p = 0.031$）。其三，也是最值得报告的否定结果：在同样的先验与约束之上再让语言模型逐轮调整规则，与规则完全冻结的版本没有可测量的差别（8.070 对 8.031，Wilcoxon $p = 1.000$）；而把语言模型当作挑选器的两个臂（7.617、7.595）与预测器贪心（7.595）在 15 个种子里有 14 个完全相同。在这道题上起作用的是进入第一轮的信息和显式约束，不是回路里有没有语言模型。

代码、证据库、全部实验记录与本文源码：https://github.com/Sunrich-HT/gb1-directed-evolution-agent


## 1 引言

定向进化的每一轮都要回答同一个问题：在有限的测量预算下，下一批测什么。机器学习指导的做法 [1, 2, 3, 4]是用已测数据拟合 一个适应度预测器，再按预测值排序取前 $k$ 个。这个做法有两个已知弱点：预测器在标签稀少时对高值区间的识别 能力很差；而贪心排序会让批次塌缩到同一个基序上，使下一轮的模型学不到新的东西。

把大语言模型放进回路 [5]是近年常见的补救办法，通常的叙述是"智能体能结合先验知识做专家级判断"。本文要检验的 正是这个叙述。我们把问题拆成两个可分别测量的部分：

- **先验**：在看到任何多突变标签之前，结构坐标、物理化学规则与已发表文献到底能提供多少可用信息？
- **约束**：把"哪些候选不可接受、批次必须满足什么组成"写成显式规则，相对于单纯按预测值排序能带来什么？

两者都不需要语言模型就能实现。因此本文的对照设计里，语言模型的作用被限定为"在既有先验与约束之上逐轮修改规则"，并与规则完全冻结的版本直接对照——这是判断智能体是否真的贡献了判断力的唯一干净做法。

测试平台是 Wu 等 [6] 发布的 GB1 四位点深度突变扫描：免疫球蛋白结合域 B1 的 39/40/41/54 四个位点全组合（$20^4$）的结合适应度。该景观被反复用作上位性与机器学习指导设计的基准 [7, 1, 2]，其全局最优 FWAA （fitness 8.762）的四个组分中有两个单独出现时低于野生型，因此任何基于单突变收益的贪心策略都会在 第一步把它们丢掉。

## 2 方法

### 2.1 数据、划分与虚拟评估器

数据取自 FLIP 基准固定提交的 GB1 四位点全数据（149,361 条，SHA-256 校验写死在加载器中），野生型为 V39/D40/G41/V54。实测适应度只作为虚拟评估器：任何一批候选在被程序以 SHA-256 冻结之后 才允许揭示标签，揭示记录逐条写入 `oracle_queries.jsonl`。固定测试集 10000 条只用

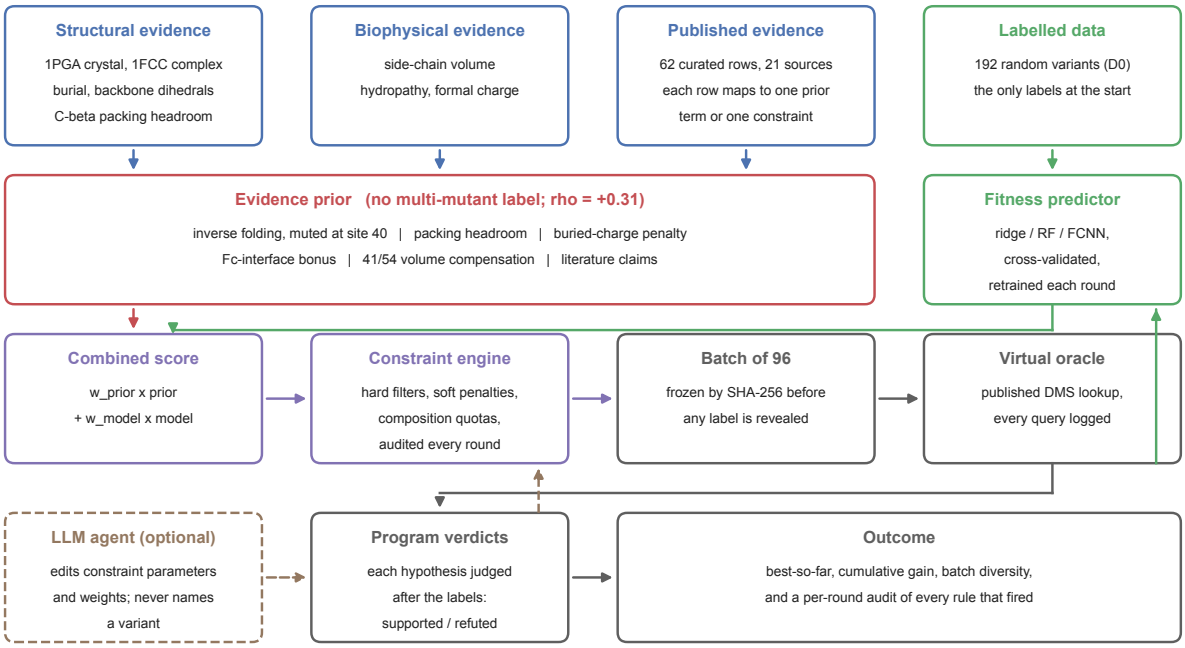



**Figure 1: 方法架构。** 结构、物化与文献证据各自编译为先验分量（上两行）；拟合预测器只使用 192 条起始标签。两者加权后进入约束引擎，由硬过滤、软惩罚与组成配额决定最终的 96 条批次；批次先以 SHA-256 冻结，再由虚拟评估器揭示标签，程序随后裁决每条登记假说，被推翻的取代自动转为下一轮的惩罚项。语言模型（左下，虚线）只能修改规则与权重，不能点名变体；把它完全移除（`prior_fixed` 臂）不改变结果。

于评测预测器，任何臂都不可见；起始标签 $D_0 = 192$ 条随机变体，七个臂共用同一个 $D_0$ 与同一个候选池 $U = 139169$ 条，池内包含全局最优。每轮预算 96 条，共 3 轮，15 个随机种子。

## 2.2 证据先验

先验是一张 $4 \times 20$ 的取代打分表加一个位点对交互项，由若干可独立关闭的分量加权合成，每个分量都标注其证据来源（完整定义见 `src/gb1agent/evidence.py`）：

- **反折叠分数**：ProteinMPNN [8]（soluble `v_48_002`，钉定提交与权重校验和）在 GB1 骨架上的 $\log p(\text{突变} \mid \text{骨架}) - \log p(\text{野生型} \mid \text{骨架})$。**在 40 位被置零**：已有工作报告零样本集成把 D40 的全部 19 种取代都判为不利 [9]，而实测相反。
- **堆积余量**：用 N、CA、C 重建每个位点的虚拟 C$\beta$（与晶体结构 1PGA [10] 中 V39、V54 的实测 C$\beta$ 偏差分别为 0.05 Å 与 0.11 Å），测量其到最近非相邻重原子的距离。41 位仅 2.11 Å（到 55 位羰基氧），39/54 位分别为 3.51 与 3.69 Å，因此只有 41 位对增大的侧链体积施加惩罚。
- **埋藏电荷惩罚**：按 Shrake – Rupley 相对可及度（1PGA）缩放，39 位 6.4%、54 位 1.1%。
- **界面加成**：只有在 IgG-Fc 复合物 1FCC [11] 中真正埋藏表面的位点才获得大侧链/芳香族加成，按 $\Delta$SASA 计算为 40 位 41.9 Å$^2$，而 39/41/54 位分别只有 1.7、7.2 与 0.5 Å$^2$。
- **41 – 54 体积补偿（位点对项）**：已发表双突变图谱中最强的正上位性 G41L/V54G [7] 的机制是把侧链体积从埋藏的 Val54 转移到 41 位所在的环；本项对 $\Delta V_{41} + \Delta V_{54} \approx 0$ 的组合加分。
- **文献条目**：62 条结构化证据中可映射到具体取代的条目，按其置信度加权。

**证据来源。** 证据库共 21 个来源，涵盖 GB1 的晶体与 NMR 结构、IgG-Fc 与 Fab 复合物、单分子力谱、碱性稳定性工程改造，以及机器学习指导定向进化与零样本预测的方法学工作；本文参考文献列出其全部条目，正文只在用到某条证据处显式引用。

**泄漏纪律。** 任何来源于本任务所用深度突变扫描的测量条目默认被排除；实测单突变加性先验只作为上界参照单独报告，不参与任何一个臂。唯一一处由实测数据反向影响设计的决定是：对称体

积项在量化评测后 被关闭（见表 1），这一点在此明确披露。

**一处被证伪的结构假设。** 本工作的早期版本按 NMR 结构 2GB1 [12, 13]（41 位 $\psi = -97.4°$）加入了"41 位必须是甘氨酸"的硬过滤。晶体结构 1PGA 给出 $\phi/\psi = -137.6°/-159.8°$，属于非甘氨酸同样允许的 $\beta$ 区；该环上真正需要甘氨酸的是 $\phi \approx +77°$ 的 G38，而 38 位不可变。因此该过滤被删除，41 位的约束改为可被 54 位补偿的侧链堆积罚项。

### 2.3 约束引擎

约束是数据而不是代码分支，每条声明 id、类型（硬过滤 / 软惩罚 / 组成配额）、参数与证据来源（`src/gb1agent/constraints.py`）。每轮产出审计记录：每条过滤删除了多少候选、每项惩罚的平均贡献、配额是否起作用、最终批次与"无约束排序"相比改变了多少个名额。约束集包含：不重复测量、低堆积余量位点的体积上限、埋藏电荷惩罚、批次多样性配额（每位点最少氨基酸种类与单一氨基酸占比上限）、探索配额、以及由程序裁决的假说反馈项（被推翻的取代降权，被支持的加权）。

### 2.4 七个臂

`random`（均匀抽样）、`greedy`（预测器前 $k$）、`greedy_explore`（75% 贪心 + 25% 随机）、`llm_agent`（LLM 从模型排序的候选名单中挑选）、`llm_knowledge`（同前，附加知识块与零样本列）、`prior_fixed`（证据先验 + 约束，规则冻结，**不含语言模型**）、`prior_constraint`（同前，但每轮由 DeepSeek-chat 阅读上一轮结果、约束审计与逐位点统计后，提出对约束参数与先验/模型权重的具体修改并给出可检验假说）。语言模型调用全部为真实 API 调用，共 154 次、合计 0.523 美元，逐条账本随仓库提交；预算设硬上限，超限即停，失败不自动重试。

### 2.5 评价指标

末轮 best-so-far、命中全局最优的种子数、累计收益、批次多样性（平均成对汉明距离）、以及预测器在固定测试集上的 Spearman $\rho$、top-100 召回与 top-5% 精度。臂与臂之间按种子配对比较：连续指标用 Wilcoxon 符号秩检验（去掉完全相同的种子），命中率用配对 McNemar 精确检验。

## 3 结果

### 3.1 第一轮之前就能知道的事

四个可变位点在机制上并不等价（图 2a）。在 IgG-Fc 复合物中，只有 40 位在结合时埋藏可观表面（41.9 Å$^2$），39、41、54 位分别只有 1.7、7.2、0.5 Å$^2$；而 39 与 54 位在游离结构中近乎完全埋藏（相对可及度 6.4% 与 1.1%）。换言之，40 位可以通过界面直接影响结合，另外三个位点只能通过折叠稳定性与环的构象间接起作用。

把这些结构事实、物理化学规则与文献条目合成的先验（图 2b），在不使用任何多突变标签的前提下，在三突变以上子集上达到 $\rho = +0.295$，与使用实测单突变标签的上界 $\rho = +0.294$ 持平（表 1）。更重要的是操作层面的指标：该先验排序的前 96 名中最好变体为 6.124，高于实测单突变先验的 5.772，相对随机的 top-1% 富集为 17.7×。单独看各分量：仅反折叠分数只有 $\rho = +0.170$，仅文献条目 $\rho = +0.219$，仅堆积余量 $\rho = +0.091$——没有任何单一来源能单独支撑第一轮，合成才有用。

### 3.2 七臂对照

在同起点、同预算下（表 2、图 3），模型指导相对随机采样的收益是决定性的：末轮最好 7.595 对 4.336。在此之上：

- **证据先验 + 约束显著提高了命中率。** 命中全局最优的种子比例从预测器贪心的 20% 升到 60%（9/15）。配对比较中它赢 7 个种子、输 3 个、平 5 个，Wilcoxon $p = 0.080$；按命中与否做配对 McNemar 检验，不一致对为 6:0，精确 $p = 0.031$。
- **语言模型在这之上没有可测量的增量。** 让 DeepSeek 每轮修改约束与权重，末轮最好为 8.070，与规则冻结版本的 8.031 相比，赢 2 输 3 平 10，Wilcoxon $p = 1.000$，命中率两者同为 60%。
- **把语言模型当挑选器基本等于贪心。** `llm_agent` 末轮最好 7.617，与 `greedy` 的 7.595 在 15 个种

Table 1: 零样本先验的质量。* 实测单突变加性先验使用了与虚拟评估器同源的标签，只作为上界参照， 不参与任何一个臂。对称体积项在量化评测后被关闭：它使排序变差。

| 先验 | $\rho$（全景） | $\rho$（≥3 突变） | top-5% 精度 | 前 96 内最好 | top-1% 富集 |
|---|---|---|---|---|---|
| 随机排序 | -0.002 | -0.001 | 0.049 | 1.13 | 0.0× |
| 仅反折叠（ProteinMPNN） | +0.183 | +0.170 | 0.188 | 3.90 | 11.5× |
| 仅堆积余量 | +0.105 | +0.091 | 0.294 | 3.93 | 7.3× |
| 仅文献条目 | +0.215 | +0.219 | 0.119 | 7.31 | 27.1× |
| 完整证据先验 | +0.306 | +0.295 | 0.270 | 6.12 | 17.7× |
| 证据先验 + 对称体积项 | +0.285 | +0.274 | 0.269 | 6.12 | 16.7× |
| 实测单突变加性先验* | +0.305 | +0.294 | 0.296 | 5.77 | 63.6× |

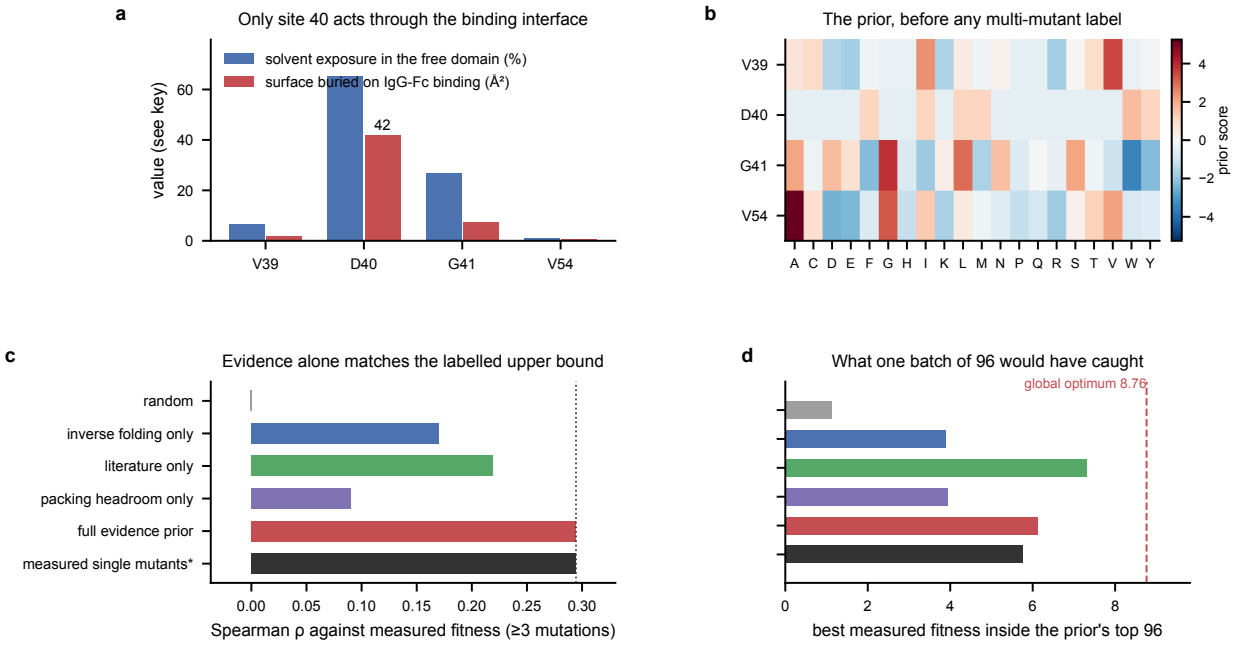



Figure 2: 第一轮之前已知的信息。 a，四个位点的机制分工：蓝色为游离结构（1PGA）中的相对溶剂可及度，红色为在 IgG-Fc 复合物 （1FCC）中结合时埋藏的表面积；只有 40 位真正位于结合界面。 b，合成后的 $4 \times 20$ 先验打分表，由反折叠分数、堆积余量、埋藏电荷、界面加成、 41 – 54 体积补偿与文献条目加权而成，不使用任何多突变标签。 c，各先验在三突变以上子集上的排序能力；虚线为使用实测单突变标签的上界， 带 * 的条目使用了与虚拟评估器同源的标签，仅作参照。 d，操作层面的指标：按该先验排序的前 96 名中最好的实测适应度。

子中有 14 个完全相同； 加入知识块后为 7.595。第一轮它几乎原样采纳预测器的前 96 名，之后才逐渐偏离。

- **单纯加探索不够。** `greedy_explore`（25% 随机探索）末轮最好 7.129， 低于贪心本身——无方向的探索摊薄了预算，有方向的约束才有用。

### 3.3 决策为什么是可审计的

图 4 给出三层证据。每个入选变体的先验分数可以拆回到具体证据分量（图 4a）， 因此”为什么选它”有数值答案而不是叙述。约束审计记录每轮删除的候选数与被配额挡下的名额 （图 4b），并给出与无约束排序相比被改变的名额数（图 4d）： 规则确实在改变批次，而不是装饰。539 条登记假说由程序在标签揭示后裁决， 支持 188 条、推翻 128 条、证据不足 223 条（图 4c）， 被推翻的取代在下一轮自动降权。

### 3.4 景观本身的机制

图 5 解释了上述差距的来源。成对编码模型中交互项占全部权重的 83%， 即上位性是这张景观的主体而非修正项。先验中假设的 41 – 54 体积转移机制在实测数据中可见： 按 $|\Delta V_{41} + \Delta V_{54}|$ 分箱后，

Table 2: 七臂对照（15 个随机种子，192 条起始标签 + 3 轮 × 96 条）。 全局最优为 FWAA（fitness 8.762）。

| 方法 | 末轮最好（均值） | 中位数 | 范围 | 命中全局最优 | 累计收益 | 批次多样性 |
|---|---|---|---|---|---|---|
| 随机对照 | 4.34 | 4.44 | 2.02 – 7.23 | 0/15 | 1.53 | 3.80 |
| 预测器贪心 | 7.60 | 7.31 | 6.34 – 8.76 | 3/15 | 4.79 | 2.45 |
| 预测器 + 25% 探索 | 7.13 | 7.31 | 5.44 – 8.76 | 3/15 | 4.33 | 2.99 |
| LLM 智能体 | 7.62 | 7.55 | 6.34 – 8.76 | 3/15 | 4.81 | 2.45 |
| LLM + 知识块 | 7.60 | 7.31 | 6.34 – 8.76 | 3/15 | 4.79 | 2.47 |
| 证据先验 + 约束（无 LLM） | 8.03 | 8.76 | 5.77 – 8.76 | 9/15 | 5.23 | 3.15 |
| 证据先验 + 约束（LLM 调参） | 8.07 | 8.76 | 5.77 – 8.76 | 9/15 | 5.27 | 3.27 |

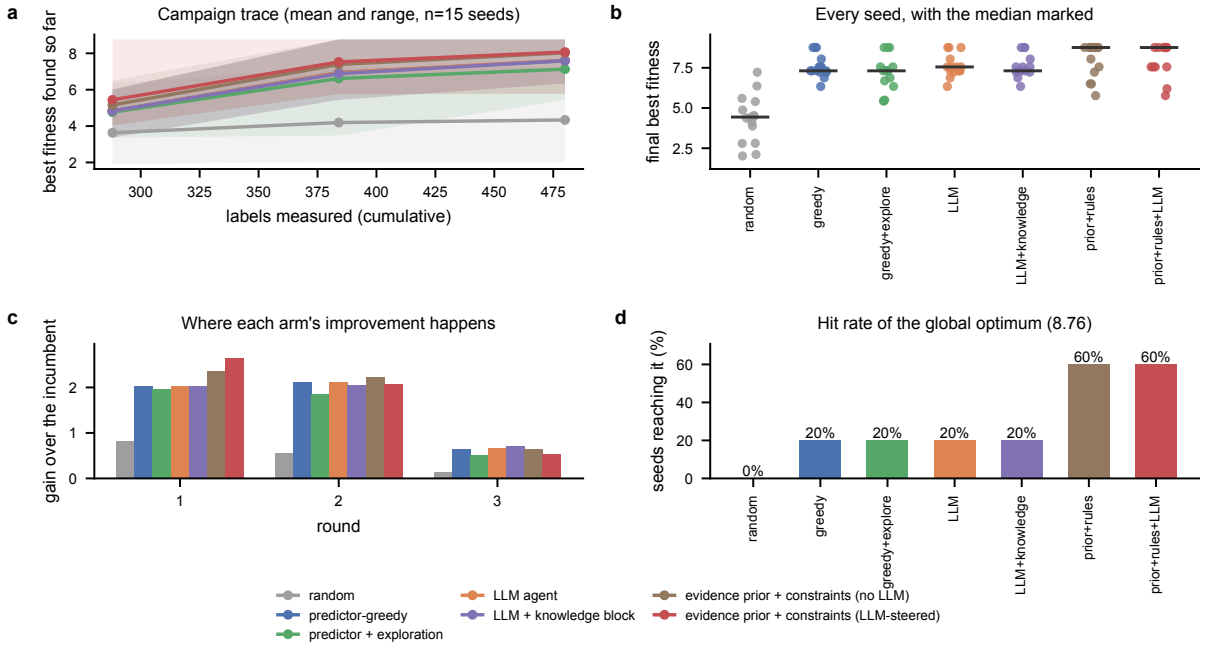



Figure 3: **七臂在同起点、同预算下的表现（15 个种子）**。 a，best-so-far 随累计标签数的变化，实线为均值、阴影为种子间极差。 b，每个种子的末轮结果与中位数横线。 c，每轮相对当前最好值的收益：第一轮贡献最大，第三轮几乎不再产生收益。 d，命中全局最优（8.762）的种子比例。两个”证据先验 + 约束”臂（含与不含语言模型） 结果相同，均为 60%。

体积平衡的组合其 99 分位适应度明显更高（图 5c）。 全局最优 FWAA 的四个组分中有两个单独出现时低于野生型，这正是单突变贪心筛选失败的原因 （图 5d）。

### 3.5 结构预测服务的实际贡献

作为加分项，我们用 NVIDIA 托管的 Boltz-2 对覆盖整个适应度量程的 146 个变体做了真实折叠 （5 个密钥轮换，中位延迟 7.3 秒）。四个突变位点的 pLDDT 与实测适应度的相关为 $\rho = +0.21$，而仅用 192 条标签训练的序列模型为 $\rho = +0.56$； 把结构置信度作为额外特征加入后，5 折交叉验证的 Spearman 变化 -0.002、top-5% 精度变化 +0.000。即：预测结构的置信度在本任务上是诚实的零贡献项。

## 4 讨论

**先验决定起跑线，约束决定批次结构。** 本文最稳的结论是：把结构坐标、物理化学与文献证据编译成显式先验， 再用带证据来源的约束塑造批次组成，可以在同样的标签预算下把命中全局最优的比例提高三倍 （20% → 60%）。这两件事都不需要语言模型，而且都是可审计的： 先验分数可以拆回分量，约束可以逐条报告它删除了什么。

**语言模型没有带来增量，这值得认真对待。** 在相同的先验与约束之上，让模型逐轮修改规则与权重， 与完全冻结规则的版本在 15 个种子上无法区分（Wilcoxon $p = 1.000$）。 而当语言模型被用作

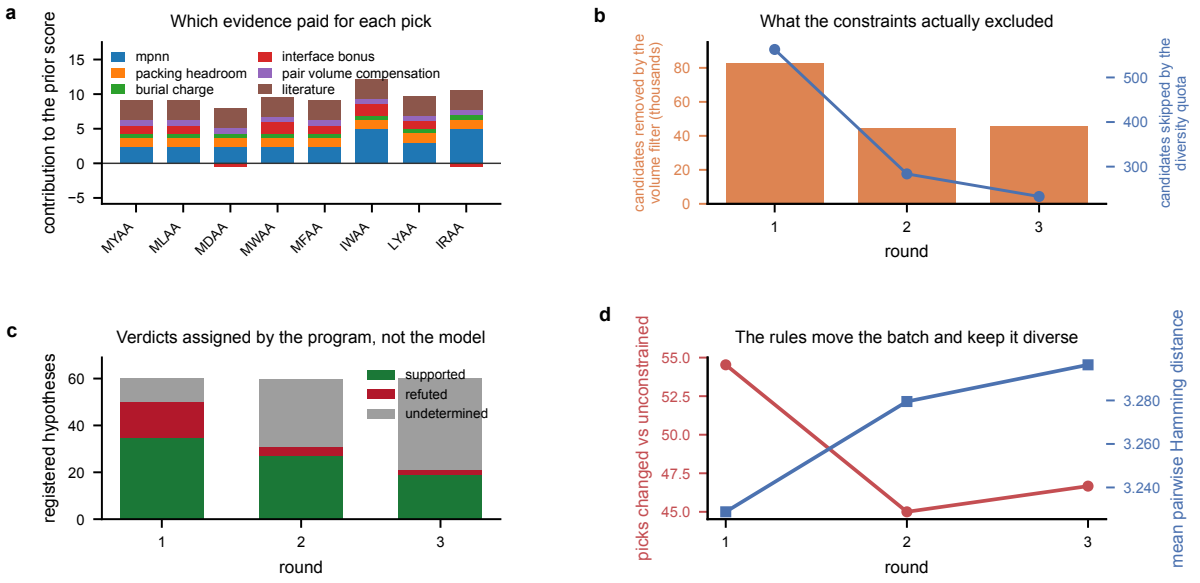



**Figure 4: 决策的可审计性（证据先验 + 约束臂）。** a，入选变体的先验分数按证据分量分解，负贡献画在零线以下。 b，约束审计：橙色柱为体积过滤删除的候选数（千），蓝线为多样性配额挡下的名额数。 c，539 条登记假说由程序在标签揭示后裁决。 d，规则的后果：与无约束排序相比被改变的名额数（红）与批次多样性（蓝）。

挑选器时，它几乎复制预测器的排序。合理的解读不是"语言模型没用"，而是： 在一个四位点、搜索空间仅 $20^4$、且已有强先验与显式约束的问题上，留给自由判断的空间很小。 语言模型的可能价值在于把文献读成结构化证据（本文的证据库正是这样产生的），而不是在回路里替代排序。

**零样本折叠分数不是结合预测。** 反折叠（ProteinMPNN）与结构预测（Boltz-2）[14, 15, 16, 17, 9] 在本任务上都只提供 很弱的信号：前者单独 $\rho = +0.170$，后者的置信度与适应度相关 $\rho = +0.21$，作为特征加入后变化为 -0.002。它们预测的是"这条序列能不能折叠成这个骨架"， 而本任务的目标是与 IgG-Fc 的结合——两者在 40 位尤其不一致，这也是我们在该位点把零样本权重置零的原因。

## 5 局限

- 全部"测量"都是在已发表的深度突变扫描上查表，不是湿实验；该数据集约 6.6% 的变体为插补值。
- 15 个随机种子。命中率差异的配对 McNemar 检验 $p = 0.031$， 但连续指标的 Wilcoxon 检验为 $p = 0.080$，处在边界。
- 结论来自一个四位点景观与一个语言模型；位点更多、先验更弱的任务上结论可能不同。
- 证据库中专利条目为 0 条：检索接口不可用，没有读到任何权利要求。

**声明。** 本工作的代码实现、文献证据抽取与文稿撰写由 AI 助手协助完成。 外部服务：LLM 调用 154 次（0.523 美元），NVIDIA 托管 Boltz-2 折叠 146 个变体； 仓库中不含任何密钥。

## References

[1] Bruce J. Wittmann, Yisong Yue, and Frances H. Arnold. Informed training set design enables efficient machine learning-assisted directed protein evolution. Cell Systems, 12(11):1026 – 1045.e7, 2021. doi: 10.1016/j.cels.2021.07.008.

[2] Yuchi Qiu, Jian Hu, and Guo - Wei Wei. Cluster learning-assisted directed evolution. Nature Computational Science, 1(12):809 – 818, 2021. doi: 10.1038/s43588-021-00168-y.

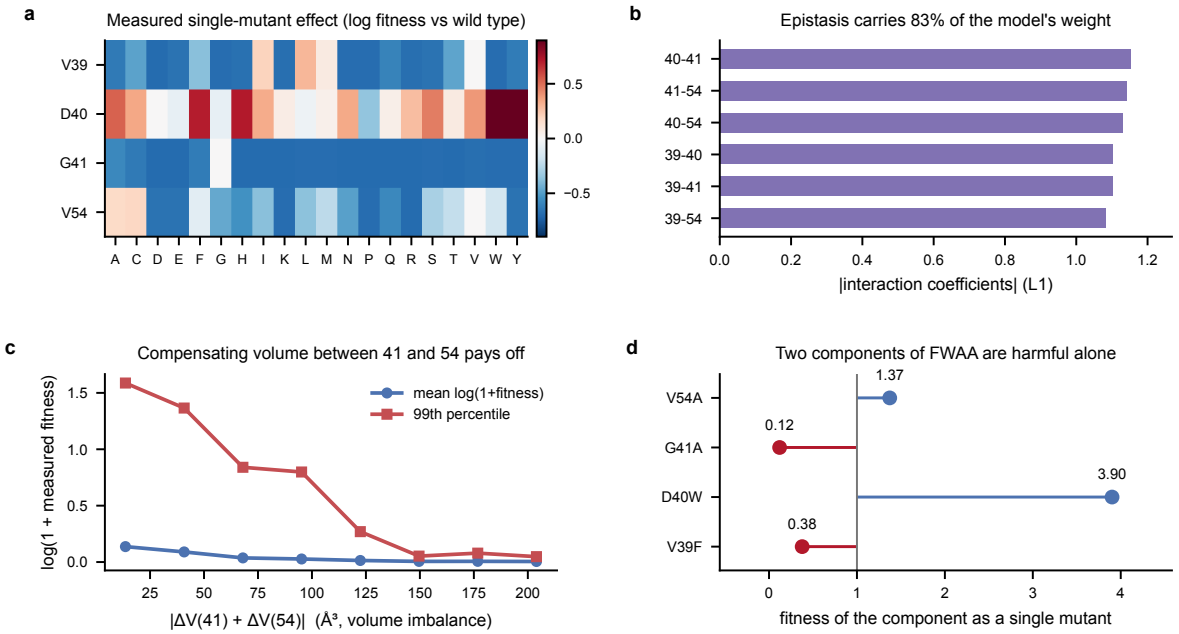



**Figure 5: 景观机制与失败模式。** a，实测单突变效应谱。 b，成对编码模型中各位点对的交互强度，交互项合计占全部权重的 83%。 c，先验中假设的 41 – 54 体积转移机制在实测数据中的表现：按 $|\Delta V_{41} + \Delta V_{54}|$ 分箱，体积平衡的组合其 99 分位适应度明显更高。 d，全局最优 FWAA 的四个组分单独出现时的适应度，红色为低于野生型者。


[3] Jason Yang, Ravi Lal, James C. Bowden, Raul Astudillo, Mikhail A. Hameedi, Sukhvinder Kaur, Matthew Hill, Yisong Yue, and Frances H. Arnold. Active learning-assisted directed evolution. Nature Communications, 16(1):714, 2025. doi: 10.1038/s41467-025-55987-8.

[4] Kerr Ding, Michael Chin, Yunlong Zhao, Wei Huang, Binh Khanh Mai, Huanan Wang, Peng Liu, Yang Yang, and Yunan Luo. Machine learning-guided co-optimization of fitness and diversity facilitates combinatorial library design in enzyme engineering. Nature Communications, 15(1):6392, 2024. doi: 10.1038/s41467-024-50698-y.

[5] Vincent Q. Tran, Matthew Nemeth, Liam J. Bartie, Sita S. Chandrasekaran, Alison Fanton, Hyungseok C. Moon, Brian Hie, Silvana Konermann, and Patrick D. Hsu. Rapid directed evolution guided by protein language models and epistatic interactions. Science, 392(6798):eaea1820, 2026. doi: 10.1126/science.aea1820.

[6] Nicholas C. Wu, Lei Dai, C. Anders Olson, James O. Lloyd - Smith, and Ren X. Sun. Adaptation in protein fitness landscapes is facilitated by indirect paths. eLife, 5, 2016. doi: 10.7554/elife.16965.

[7] C. Anders Olson, Nicholas C. Wu, and Ren Sun. A Comprehensive Biophysical Description of Pairwise Epistasis throughout an Entire Protein Domain. Current Biology, 24(22):2643 – 2651, 2014. doi: 10.1016/j.cub.2014.09.072.

[8] Justas Dauparas, Ivan V. Anishchenko, Nathaniel R. Bennett, Hua Bai, Robert J. Ragotte, Lukas F. Milles, Basile I. M. Wicky, Alexis Courbet, Robbert J. de Haas, Neville P. Bethel, Philip J. Y. Leung, Timothy F. Huddy, Samuel J. Pellock, Doug Tischer, F. Chan, Brian Koepnick, Hannah Nguyen, Alex Kang, Banumathi Sankaran, Asim K. Bera, Neil P. King, and David A. Baker. Robust deep learning – based protein sequence design using ProteinMPNN. Science, 378(6615):49 – 56, 2022. doi: 10.1126/science.add2187.

[9] Exploring zero-shot structure-based protein fitness prediction. arXiv:2504.16886, 2025. preprint.

[10] Travis Gallagher, Patrick Alexander, Philip N. Bryan, and Gary L. Gilliland. Two Crystal Structures

of the B1 Immunoglobulin-Binding Domain of Streptococcal Protein G and Comparison with NMR. Biochemistry, 33(15):4721 – 4729, 1994. doi: 10.1021/bi00181a032.

[11] A.E. Sauer-Eriksson, Gerard J. Kleywegt, Mathias Uhlén, and T. Alwyn Jones. Crystal structure of the C2 fragment of streptococcal protein G in complex with the Fc domain of human IgG. Structure, 3(3): 265 – 278, 1995. doi: 10.1016/s0969-2126(01)00157-5.

[12] Angela M. Gronenborn, David R. Filpula, Nina Z. Essig, Aniruddha Achari, Marc D. Whitlow, Paul T. Wingfield, and G. Marius Clore. A Novel, Highly Stable Fold of the Immunoglobulin Binding Domain of Streptococcal Protein G. Science, 253(5020):657 – 661, 1991. doi: 10.1126/science.1871600.

[13] Angela M. Gronenborn and G. Marius Clore. Identification of the Contact Surface of a Streptococcal Protein G Domain Complexed with a Human Fc Fragment. Journal of Molecular Biology, 233(3): 331 – 335, 1993. doi: 10.1006/jmbi.1993.1514.

[14] Pascal Notin, Aaron W. Kollasch, Daniel Ritter, Lood van Niekerk, Steffan B. Paul, Hansen Spinner, Nathan J. Rollins, Ada Y. Shaw, Ruben Weitzman, Jonathan Frazer, Mafalda Dias, Dinko Franceschi, Rose Orenbuch, Yarin Gal, and Debora S. Marks. ProteinGym: Large-Scale Benchmarks for Protein Design and Fitness Prediction. bioRxiv, 2023. preprint.

[15] Joshua Meier, Roshan Rao, Robert Verkuil, Jason J. Liu, Tom Sercu, and Alexander W. Rives. Language models enable zero-shot prediction of the effects of mutations on protein function. bioRxiv, 2021. preprint; also published in Advances in Neural Information Processing Systems 34 (2021).

[16] Chloe Hsu, Hunter Nisonoff, Clara Fannjiang, and Jennifer Listgarten. Learning protein fitness models from evolutionary and assay-labeled data. Nature Biotechnology, 40(7):1114 – 1122, 2022. doi: 10.1038/s41587-021-01146-5.

[17] Thomas A. Hopf, John Ingraham, Frank J. Poelwijk, Charlotta Schärfe, Michael Springer, Chris Sander, and Debora S. Marks. Mutation effects predicted from sequence co-variation. Nature Biotechnology, 35(2):128 – 135, 2017. doi: 10.1038/nbt.3769.

[18] Tianjia Bu, Hui - Chuan Eileen Wang, and Hongbin Li. Single Molecule Force Spectroscopy Reveals Critical Roles of Hydrophobic Core Packing in Determining the Mechanical Stability of Protein GB1. Langmuir, 28(33):12319 – 12325, 2012. doi: 10.1021/la301940g.

[19] Jeremy P. Derrick and Dale B. Wigley. The Third IgG-Binding Domain from Streptococcal Protein G. Journal of Molecular Biology, 243(5):906 – 918, 1994. doi: 10.1006/jmbi.1994.1691.

[20] Susanne Gülich, Martin Linhult, Stefan Ståhl, and Sophia Hober. Engineering streptococcal protein G for increased alkaline stability. Protein Engineering, Design and Selection, 15(10):835 – 842, 2002. doi: 10.1093/protein/15.10.835.

[21] B PALMER, Katy Angus, L TAYLOR, Jim Warwicker, and Jeremy P. Derrick. Design of stability at extreme alkaline pH in streptococcal protein G. Journal of Biotechnology, 134(3-4):222 – 230, 2008. doi: 10.1016/j.jbiotec.2007.12.009.

## A 附录：一个完整案例（种子 302）

本附录把一次完整的三轮实验逐步摊开：先验如何给出第一批候选、约束删掉了什么、程序如何裁决假说、智能体据此改了哪些规则，以及最终在哪一轮命中全局最优。选择这个种子的原因是它能把本文的核心理念 摆在同一条时间线上——同样的起点下，预测器贪心止步于 6.878，而证据先验加约束命中了 FWAA（8.762）。

## A.1 在看到任何标签之前，先验怎么看待全局最优

全局最优 FWAA 的四个取代中有两个（V39F、G41A）单独出现时低于野生型，因此任何以单突变收益排序的策略 都会丢掉它。证据先验不按单突变收益打分，而是把结构与文献证据加起来：

| 先验分量 | FWAA | 野生型 VDGV |
|---|---|---|
| 反折叠分数 | +2.427 | +7.389 |
| 堆积余量 | +1.305 | +2.012 |
| 埋藏电荷 | +0.618 | +0.618 |
| Fc 界面加成 | +1.625 | -0.520 |
| 41/54 体积补偿 | +0.827 | +0.284 |
| 文献条目 | +2.771 | -0.563 |
| 合计 | **+9.573** | +9.220 |

在全部 149,361 条变体中，该先验把 FWAA 排在第 911 位（前 0.61%），而这一排名没有用到任何多突变标签。 把它托起来的主要是文献条目（+2.771）与 Fc 界面加成（+1.625）：前者来自双突变图谱中 V54A 背景下 41 位由有害转为有利的报告，以及 41/54 之间的体积转移机制；后者来自复合物结构中只有 40 位埋藏表面 这一事实。

| 编号 | 证据陈述（摘要） | 来源 |
|---|---|---|
| EV019 | V54A is functionally neutral on its own, yet in the V54A background substitutions at Gly41 change from deleterious to beneficial. | PMID:25455030 |
| EV020 | The most extreme case of positive epistasis in the GB1 double-mutant map, G41L/V54G, works by exchanging side-chain volume from the buried ... | PMID:25455030 |
| EV034 | In the crystal structure of a protein G IgG-binding domain bound to the Fc fragment of human IgG (PDB 1FCC), Asp40 buries about 38 Å$^2$ of ... | PMID:7788293 |
| EV053 | A zero-shot ensemble of unsupervised models predicted all 19 possible substitutions at GB1 position D40 to be disadvantageous, whereas the ... | PMID:39080249 |

## A.2 三轮的逐轮记录

规则修改在提出的当轮即生效，因此下面按”先改规则、再看结果”的顺序排列。

**第 1 轮。** 读过上一轮的审计记录与逐位点统计后，智能体把权重设为 $w_{\text{prior}} = 1.0$、$w_{\text{model}} = 1.0$，并提出以下规则修改（原话节选）：

| 约束 | 本轮生效的参数 | 理由（智能体原话，节选） |
|---|---|---|
| C7_interface_contact | weight = 0.5 | Site 40 buries 41.9 Å$^2$ against Fc and W/H top the data; penalise removing all large side chains there. |
| C2_volume_window | max_added_volume = 60 | Keep cap; G41L/V54G epistasis shows strain is compensable, so cap not ban. |
| C6_exploration_quota | fraction = 0.3 | Only 192 labels and tail unreliable; widen exploration slightly to test epistasis. |

这组规则在 139,169 条候选上的实际后果：硬过滤后剩余 56,443 条（C2 删除 82,726 条），探索配额留出 29 个名额， 多样性配额挡下 1 个候选，最终批次在四个位点上分别出现 19/19/8/18 种氨基酸；与同样分数下的”无约束排序”相比， 有 85 个名额被规则改变。本轮批次最好 4.035、均值 0.491，累计最好值 4.035。

标签揭示后，本轮登记的 4 条假说由程序裁决：推翻 3 条、证据不足 1 条。

被推翻的例子：“At site 54, threonine is enriched among high-fitness variants relative to alanine and glycine.”——带该取代的 30 个变体均值 0.284，不带的均值 0.584，差值 -0.300， 方向与假说相反，因此该取代进入 `C8` 惩罚项，在下一轮被降权。

**第 2 轮。** 读过上一轮的审计记录与逐位点统计后，智能体把权重设为 $w_{\text{prior}} = 1.0$、$w_{\text{model}} = 1.4$，并提出以下规则修改（原话节选）：

| 约束 | 本轮生效的参数 | 理由（智能体原话，节选） |
|---|---|---|
| C2_volume_window | max_added_volume = 90 | G41L/V54G compensation and LWGT success suggest the 60 Å$^3$ cap over-pruned useful site-41 bulk |
| C7_interface_contact | weight = 0.2 | W at 40 was refuted as top; lower weight so Fc-contact bonus stops inflating tryptophan |
| C8_refuted_substitutions | V54T 1, D40W 1, V39A 1, V39I 0.5; weight = 1 | V39A refuted; add mild penalty on V39I given site-39 isoleucine underperformed alanine/valine |

这组规则在 139,073 条候选上的实际后果：硬过滤后剩余 76,845 条（C2 删除 62,228 条），探索配额留出 29 个名额， 多样性配额挡下 155 个候选，最终批次在四个位点上分别出现 20/20/11/16 种氨基酸；与同样分数下的"无约束排序"相比， 有 47 个名额被规则改变。本轮批次最好 8.762、均值 1.883，累计最好值 8.762。

标签揭示后，本轮登记的 4 条假说由程序裁决：证据不足 4 条。

**第 3 轮。** 读过上一轮的审计记录与逐位点统计后，智能体把权重设为 $w_{\text{prior}} = 1.2$、$w_{\text{model}} = 0.8$，并提出以下规则修改（原话节选）：

| 约束 | 本轮生效的参数 | 理由（智能体原话，节选） |
|---|---|---|
| C2_volume_window | 停用 | Removed 62k of 139k candidates; G41L/V54G epistasis shows strain is compensable, so cap is over-restrictive. |
| C7_interface_contact | 停用 | Site 40 top variants include W and Y; penalizing loss of large side chains conflicts with observed W/F/Y gains. |
| C8_refuted_substitutions | V54T 1, D40W 1, V39A 1, V39I 0.5; weight = 0.5 | Keep refuted-substitution penalty but halve weight; verdicts were undetermined, so evidence is weak. |
| C6_exploration_quota | fraction = 0.35 | Model badly under-predicted top variants (0.93 vs 8.76); more tail exploration needed. |

这组规则在 138,977 条候选上的实际后果：硬过滤后剩余 138,977 条（本轮无硬过滤删除候选），探索配额留出 34 个名额， 多样性配额挡下 95 个候选，最终批次在四个位点上分别出现 19/19/18/17 种氨基酸；与同样分数下的"无约束排序"相比， 有 45 个名额被规则改变。本轮批次最好 6.509、均值 2.036，累计最好值 8.762。

标签揭示后，本轮登记的 4 条假说由程序裁决：证据不足 4 条。

## A.3 决定性的一次选择

第 2 轮的批次里出现了 FWAA。当时拟合预测器给它的预测值只有 0.932，在这 96 个入选变体中排第 33 位—— 如果只按模型排序，它不会进入本轮批次（同种子的预测器贪心臂第 2 轮最好只有 6.690，三轮结束为 6.878）。 把它选进来的是先验：它在先验排序中位于前 0.61%。揭示标签后其实测适应度为 8.762，即全局最优。 这一次选择就是本文主张的具体形态：当模型在标签稀少时对高值区间失灵，先验与约束是唯一能把 正确候选留在批次里的东西。

## A.4 同一种子下三种策略的对照

| 轮次 | 预测器贪心 | 证据先验+约束（无 LLM） | 证据先验+约束（LLM 调参） |
|---|---|---|---|
| 第 1 轮 | 4.597 | 4.035 | 4.035 |
| 第 2 轮 | 6.690 | 8.762 | 8.762 |
| 第 3 轮 | 6.878 | 8.762 | 8.762 |

两个带先验与约束的臂在第 2 轮同时命中全局最优，而且带不带语言模型结果相同——这与正文第 3 节 在 15 个种子上的统计结论一致。

## A.5 这个案例说明了什么

- **先验决定了第一轮看得见什么。** 全局最优在先验里排前 0.61%，在单突变收益排序里则被两个有害组分挡在外面；第一批 96 条候选能否包含通往最优的中间体，在任何模型被拟合之前就已经确定。
- **约束是可审计的，而不是修辞。** 每一轮都能回答"删掉了多少、改变了几个名额、哪条规则在起作用"：第 1 轮硬过滤删除 82,726 条、改变 85 个名额，第 3 轮智能体在给出理由后主动停用了两条规则。
- **语言模型的位置在规则层，不在候选层。** 本案例中它做的每件事都是改参数、给理由；把它整体移除后结果一模一样（A.4），这与正文在 15 个种子上的统计结论一致。