面向蛋白质定向进化的科学智能体：GB1 四位点景观上的五臂对照

数据：FLIP 固定提交的 GB1 四位点深度突变扫描（149,361 条实测）。虚拟评估器 = 公开实测 fitness，全程无湿实验。LLM：DeepSeek-chat 真实 API 调用。结构：NVIDIA 托管 Boltz-2 与本地 ProteinMPNN。

1 任务、数据划分与评测协议

四个可变位点为 39/40/41/54（野生型 VDGV）。固定测试集 T = 10,000 条用于预测器评测；起点标签 D0 = 192 条随机变体（五臂共用、同种子同起点）；候选池 U = 139,169 条未观测变体，其中包含全局最优 FWAA（fitness 8.762）。每轮预算 96 条，共 3 轮，3 个随机种子。每轮候选与假说在标签揭示前以 SHA-256 冻结，揭示后由程序判定假说成立与否——“智能体从反馈中学习”因此是可核验的记录，而不是叙述。

2 基线预测器：拟合能力与高值识别能力

模型（仅用 D0 = 192 标签训练）	Spearman	RMSE	top-100 召回	top-5% 精度
ridge[pairwise2480](alpha=1.0)	0.351	0.353	0.14	0.27
ridge[pairwise2480](alpha=10.0)	0.350	0.357	0.14	0.28
ridge[pairwise2480](alpha=0.1)	0.349	0.352	0.14	0.27
ridge[additive80](alpha=1.0)	0.336	0.355	0.14	0.31

FLIP 官方划分	训练量	Spearman	top-100 召回	top-5% 精度
sampled	6988	0.919	0.76	0.76
two_vs_rest	424	0.669	0.13	0.29
three_vs_rest	2990	0.820	0.30	0.58
low_vs_high	5089	0.627	0.28	0.37

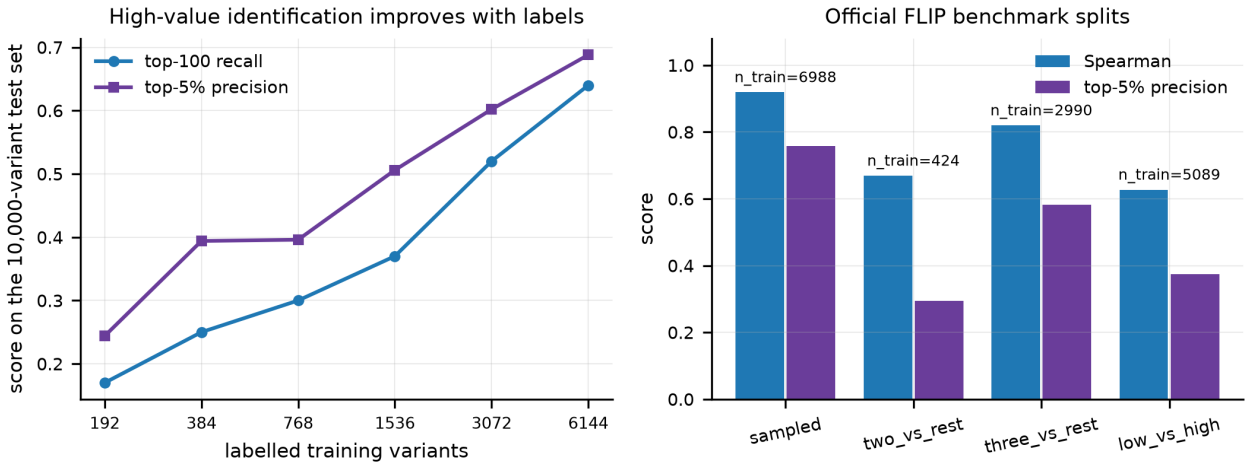


图 1 左：高值识别能力随标签量的变化（固定 10,000 条测试集）。右：四个 FLIP 官方划分上的成绩，成对编码岭回归。192 条标签只够把 top-5% 精度做到 0.27，而 6,144 条标签可到 0.69——本任务的瓶颈是标签预算，不是模型容量。

3 五方法闭环对比（3 轮 × 96 条/轮 × 3 种子）

方法	末轮 best-so-far（均值）	各种子末轮最好	命中全局最优	累计收益 G	批次多样性
随机对照	4.376	3.88 / 4.37 / 4.88	0/3	2.10	3.80
预测器贪心	7.670	8.76 / 6.69 / 7.56	1/3	5.40	2.43
预测器+25%探索	7.670	8.76 / 6.69 / 7.56	1/3	5.40	3.04
LLM 智能体	7.732	8.76 / 6.88 / 7.56	1/3	5.46	2.44
知识增强 LLM 智能体	7.732	8.76 / 6.88 / 7.56	1/3	5.46	2.44

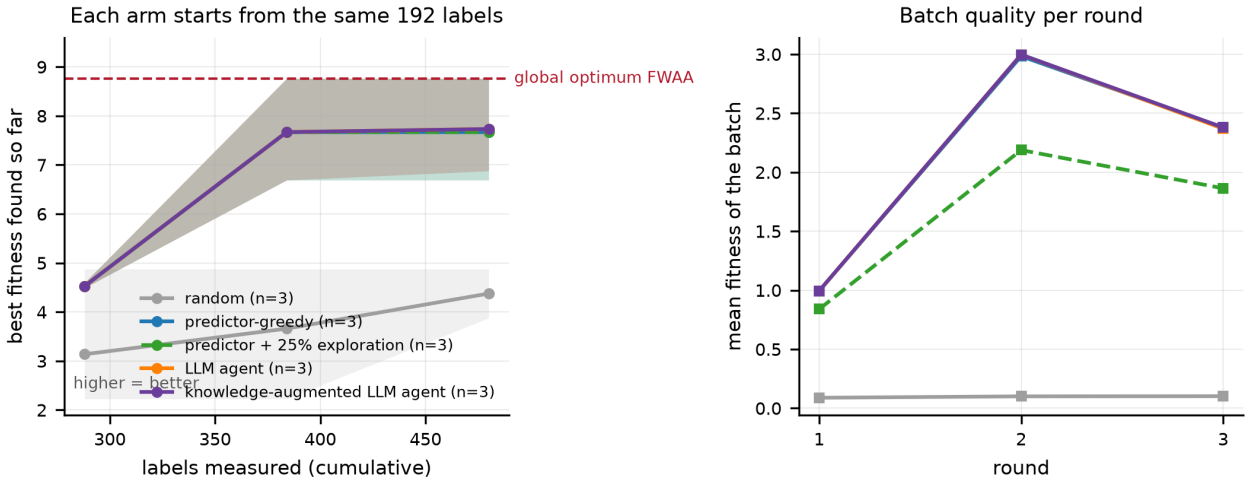


图 2 左：best-so-far 随累计标签数的变化（阴影为 3 个种子的极差）。右：每轮批次的平均 fitness。四条有模型参与的曲线几乎重合，随机对照明显落后。

结论一：模型指导相对随机采样的收益是决定性的（末轮 best-so-far 7.67 对 4.38）。结论二：在同样的 96 条预算下，LLM 智能体相对预测器贪心只有边际优势（7.732 对 7.670），知识增强臂与普通 LLM 臂几乎不可区分。这是本次实验最值得报告的负面结果，下一节用决策轨迹解释它为什么会这样。

4 可解释性：模型层、决策层、失败层

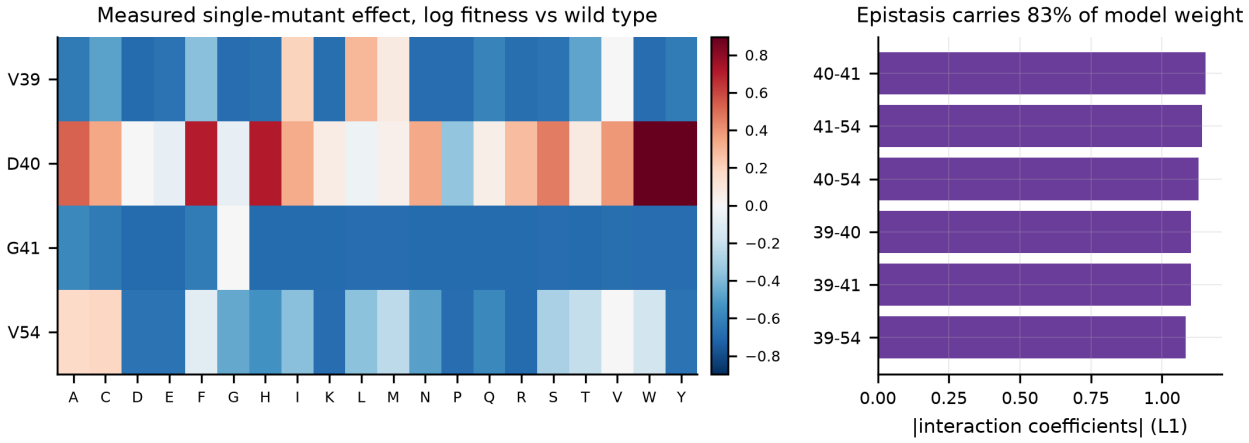


图 3 模型层。左：实测单突变效应谱（相对野生型的对数 fitness）。40 位最宽容、41 位几乎只接受甘氨酸。右：成对编码模型中交互项占全部权重的 83%——上位性不是修正项，而是这张景观的主体。

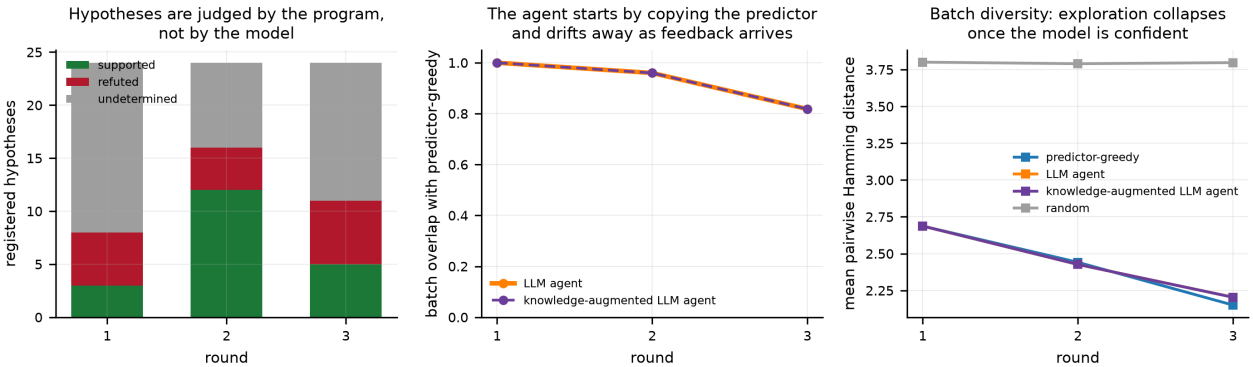


图 4 决策层。左：72 条假说由程序裁决，支持 20 条、推翻 15 条、证据不足 37 条。中：智能体第 1 轮几乎原样采纳预测器的 top-96（重合度 1.00），到第 3 轮降到 0.82——它确实在用反馈改变选择，只是改变的幅度有限。右：批次多样性随轮次下降，模型越自信，探索越少。

失败层。全局最优 FWAA（fitness 8.762）的四个组分里，V39F（0.38）、G41A（0.12）单独出现时都低于野生型（野生型归一化为 1.0）。任何以单突变收益为筛选依据的策略都会在第一步丢掉它们；三个种子里只有一个命中全局最优，根源就在这里。

5 零样本先验与结构信息到底贡献了多少

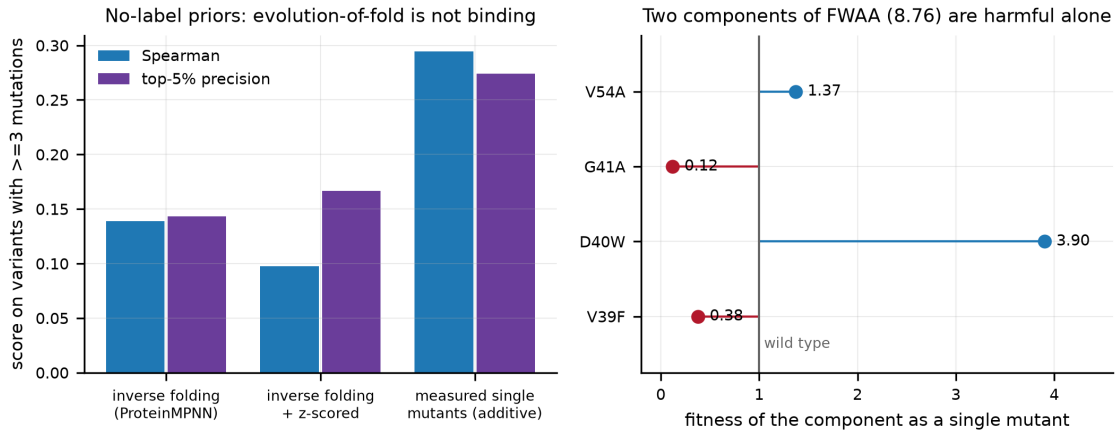


图 5
左：三种零样本先验在三突变以上变体上的质量。结构反折叠（ProteinMPNN）预测的是“这个残基与骨架相不相容”，不是“结合不结合 IgG-Fc”，因此明显弱于实测单突变加性先验。右：全局最优的组分里有两个单独有害。

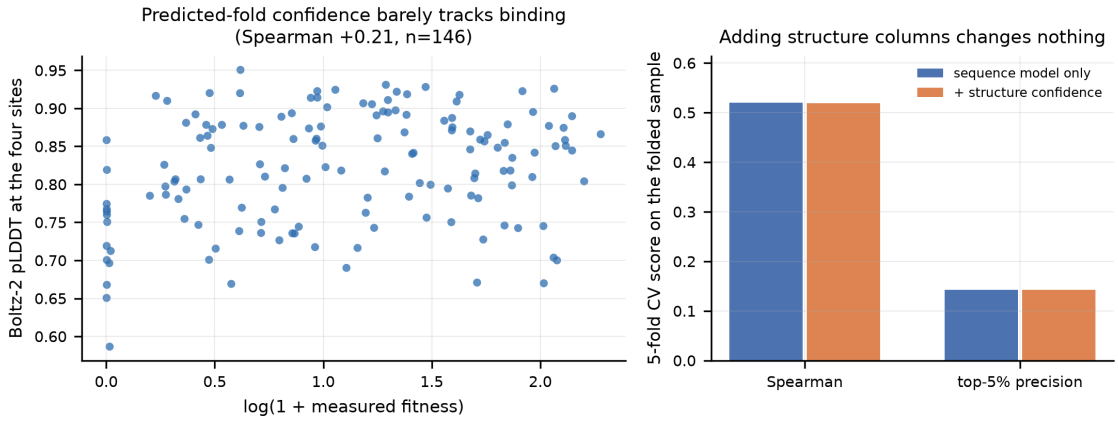


图 6 结构信息消融。左：Boltz-2 预测结构在四个突变位点上的 pLDDT 与实测 fitness 的关系（抽样覆盖整个 fitness 量程）。右：把结构置信度作为额外特征加入后的 5 折交叉验证成绩。

特征	与 fitness 的 Spearman	说明
Boltz-2 全链平均 pLDDT	+0.176	整链平均置信度；四点突变几乎不改变折叠
四个突变位点的 pLDDT	+0.210	仅取 39/40/41/54 四个位点的置信度
pTM	+0.213	整体拓扑置信度
序列模型预测值（D0 训练）	+0.559	仅用 192 条标签训练的成对编码岭回归，作为对照上限

在 146 条按 fitness 分层抽样的变体上，用 NVIDIA 托管 Boltz-2 实际折叠（5 个密钥轮换，171 次调用，中位延迟 7.3 秒）。结论：预测结构的置信度与结合 fitness 基本无关（$|\rho| \leqslant 0.21$），把它作为额外特征加进预测器后，top-5% 精度变化 +0.000、Spearman 变化 -0.002。结构模块在这道题上是诚实的零贡献项，报告它比不报告它更有意义。

6 结论、成本与披露

（1）在 288 条新增标签的预算下，模型指导把最好变体从随机采样的 4.38 提升到 7.67；（2）LLM 智能体的增量有限，且主要体现在后几轮的选择偏移上；（3）知识块与结构先验在本任务上没有可测量的增益——它们描述的是折叠，不是结合；（4）上位性占模型权重的 83%，是“单突变筛选”策略失败的根本原因。

成本与外部服务：DeepSeek-chat 真实调用 18 次，合计 0.0758 美元（账本 results/llm_deepseek/llm_ledger.json 逐条可查，设有硬上限，超限即停、失败不自动重试）；NVIDIA 托管 Boltz-2 调用见 results/structure/nvidia_receipts.jsonl（只记录密钥序号、状态码与耗时）。数据来自公开发表的 GB1 深度突变扫描（FLIP 固定提交），没有任何湿实验。代码与复现脚本见随附仓库；仓库中不含任何密钥。本报告的全部数字由 scripts/make_report.py 从 results/ 读取生成。